

## Practico 12

```
## -- Attaching packages ----- tidyverse 1.3.0 --
## v ggplot2 3.2.1    v purrr  0.3.3
## v tibble  2.1.3    v dplyr  0.8.3
## v tidyr   1.0.2    v stringr 1.4.0
## v readr   1.3.1    v forcats 0.4.0

## -- Conflicts ----- tidyverse_conflicts()--
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()

##
## Attaching package: 'magrittr'

## The following object is masked from 'package:purrr':
##
##   set_names

## The following object is masked from 'package:tidyr':
##
##   extract

## Parsed with column specification:
## cols(
##   Continent_Name = col_character(),
##   Continent_Code = col_character(),
##   Country_Name   = col_character(),
##   Two_Letter_Country_Code = col_character(),
##   Three_Letter_Country_Code = col_character(),
##   Country_Number = col_double()
## )
```

## Introducción

En este práctico (...)

En particular, utilizaremos datos de la publicación *Comparative transcriptomics analyses across species, organs, and developmental stages reveal functionally constrained lncRNAs* (Darbellay & Necseulea, 2019).

A su vez se ejemplificarán las funciones básicas a emplear con un dataset estándar empleado en muchas demostraciones: el dataset 'iris'.

# Demostración

## Leyendo datos con la librería readr

```
# cargo las librerías que utilizamos en el practico
library(magrittr)
library(tidyverse)

# cargo la tabla CSV
aeropuertos = readr::read_csv('airport-codes.csv')
```

```
## Parsed with column specification:
## cols(
##   ident = col_character(),
##   type = col_character(),
##   name = col_character(),
##   elevation_ft = col_double(),
##   continent = col_character(),
##   iso_country = col_character(),
##   iso_region = col_character(),
##   municipality = col_character(),
##   gps_code = col_character(),
##   iata_code = col_character(),
##   local_code = col_character(),
##   coordinates = col_character()
## )
```

```
# la visualizo
aeropuertos
```

```
## # A tibble: 55,907 x 12
##   ident type name elevation_ft continent iso_country iso_region municipality
##   <chr> <chr> <chr>         <dbl> <chr>      <chr>      <chr>      <chr>
## 1 00A heli~ Tota~          11 <NA>      US        US-PA      Bensalem
## 2 00AA smal~ Aero~        3435 <NA>      US        US-KS      Leoti
## 3 00AK smal~ Lowe~          450 <NA>      US        US-AK      Anchor Point
## 4 00AL smal~ Epps~          820 <NA>      US        US-AL      Harvest
## 5 00AR clos~ Newp~          237 <NA>      US        US-AR      Newport
## 6 00AS smal~ Fult~        1100 <NA>      US        US-OK      Alex
## 7 00AZ smal~ Cord~        3810 <NA>      US        US-AZ      Cordes
## 8 00CA smal~ Gold~        3038 <NA>      US        US-CA      Barstow
## 9 00CL smal~ Will~           87 <NA>      US        US-CA      Biggs
## 10 00CN heli~ Kitc~        3350 <NA>      US        US-CA      Pine Valley
## # ... with 55,897 more rows, and 4 more variables: gps_code <chr>,
## #   iata_code <chr>, local_code <chr>, coordinates <chr>
```

## Realizando modificaciones con la librería tidyr

FALTA PONER ALGO ACA

```
# realizo una modificacion con la libreria tidyr
aeropuertos %<>% tidyr::separate(data = ., col = 'coordinates', into = c('lon', 'lat'), sep = ', ')
```

```
# visualizo el resultado
aeropuertos
```

```
## # A tibble: 55,907 x 13
##   ident type name elevation_ft continent iso_country iso_region municipality
##   <chr> <chr> <chr>         <dbl> <chr>      <chr>      <chr>      <chr>
## 1 00A heli~ Tota~         11 <NA>      US        US-PA      Bensalem
## 2 00AA smal~ Aero~        3435 <NA>      US        US-KS      Leoti
## 3 00AK smal~ Lowe~         450 <NA>      US        US-AK      Anchor Point
## 4 00AL smal~ Epps~         820 <NA>      US        US-AL      Harvest
## 5 00AR clos~ Newp~         237 <NA>      US        US-AR      Newport
## 6 00AS smal~ Fult~        1100 <NA>      US        US-OK      Alex
## 7 00AZ smal~ Cord~        3810 <NA>      US        US-AZ      Cordes
## 8 00CA smal~ Gold~        3038 <NA>      US        US-CA      Barstow
## 9 00CL smal~ Will~          87 <NA>      US        US-CA      Biggs
## 10 00CN heli~ Kitc~        3350 <NA>      US        US-CA      Pine Valley
## # ... with 55,897 more rows, and 5 more variables: gps_code <chr>,
## #   iata_code <chr>, local_code <chr>, lon <chr>, lat <chr>
```

Nuestro *tibble* (clase con la que se designa a las tablas de la librería tidyverse) no posee datos en la columna *continent*. Nos deshacemos de ella utilizando la función `select()` de la librería **dplyr**.

Cargaremos otra tabla, **\*\* \*\***, en la cual se correlacionan correctamente los aeropuertos y sus continentes. Esto nos servirá más adelante, ya que haremos algunos análisis categorizando en base a continentes.

La misma está en formato alargado, por lo que tendremos que usar la función `pivot_longer()` de la librería **tidyr** para llevar a un formato alargado, tal como posee nuestro *tibble* *aeropuertos*.

Unimos estas tablas con la función `left_join` de la librería **dplyr**.

```
aeropuertos %>%
  left_join(x = ., y = pais_vs_continente.final, by = c('iso_country' = 'codigo_pais')) %>%
  dplyr::select(-continent) -> aeropuertos

aeropuertos
```

```
## # A tibble: 57,323 x 13
##   ident type name elevation_ft iso_country iso_region municipality gps_code
##   <chr> <chr> <chr>         <dbl> <chr>      <chr>      <chr>      <chr>
## 1 00A heli~ Tota~         11 US        US-PA      Bensalem    00A
## 2 00AA smal~ Aero~        3435 US        US-KS      Leoti       00AA
## 3 00AK smal~ Lowe~         450 US        US-AK      Anchor Point 00AK
## 4 00AL smal~ Epps~         820 US        US-AL      Harvest     00AL
## 5 00AR clos~ Newp~         237 US        US-AR      Newport     <NA>
## 6 00AS smal~ Fult~        1100 US        US-OK      Alex        00AS
## 7 00AZ smal~ Cord~        3810 US        US-AZ      Cordes      00AZ
## 8 00CA smal~ Gold~        3038 US        US-CA      Barstow     00CA
## 9 00CL smal~ Will~          87 US        US-CA      Biggs       00CL
## 10 00CN heli~ Kitc~        3350 US        US-CA      Pine Valley 00CN
## # ... with 57,313 more rows, and 5 more variables: iata_code <chr>,
## #   local_code <chr>, lon <chr>, lat <chr>, continente <chr>
```

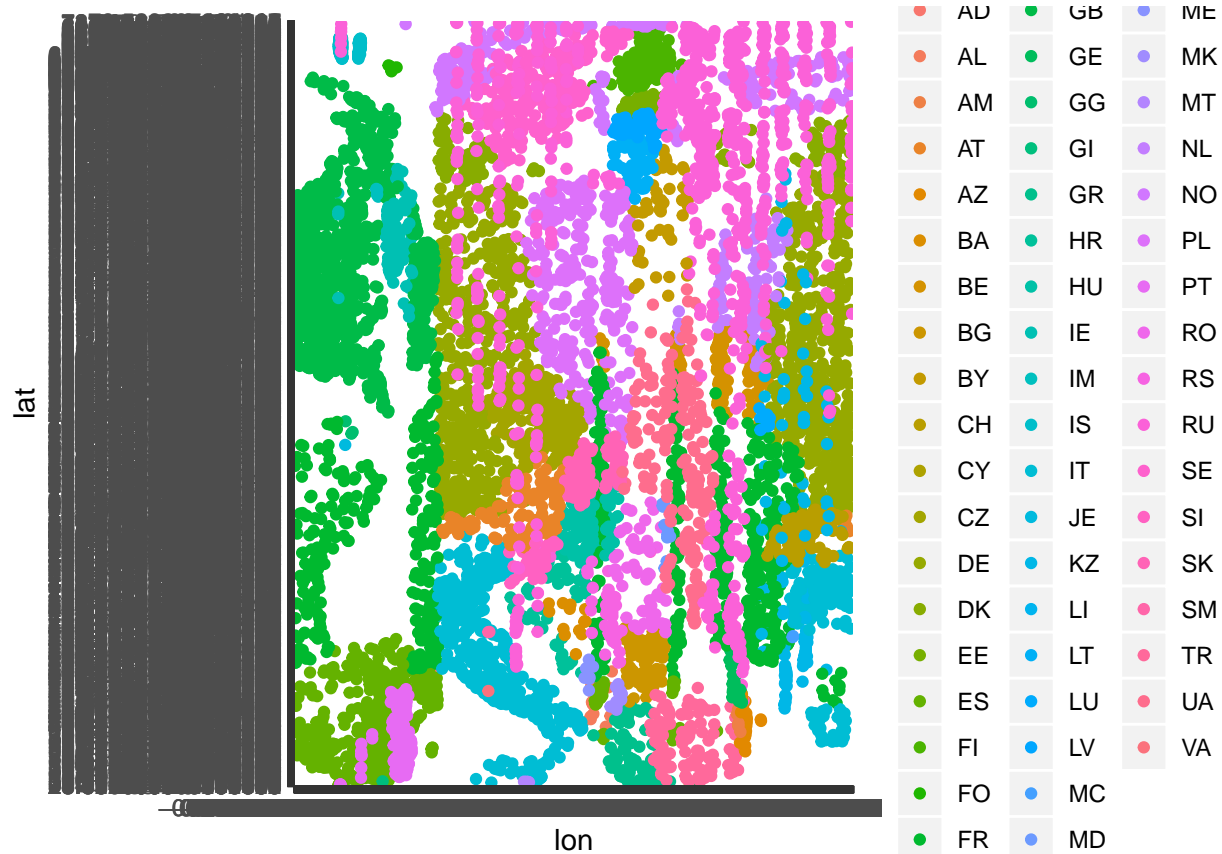
## Visualizando con la librería ggplot2

### PONER ACA COSAS DEL GGLOT2

Visualizaremos ahora nuestro set de datos. Empezaremos graficando, tomando la variable **lon** como coordenada *x* de nuestro gráfico y la variable **lat** como coordenada *y*, especificando estos argumentos con la función **aes()** de la librería.

A su vez, debemos elegir una geometría que represente a nuestros puntos. En este caso, llamaremos a la función **geom\_point()** para especificar que la misma será la geometría de puntos.


```
aeropuertos %>%
  dplyr::filter(., continente == 'Europe') %>%
  ggplot(data = .,
    mapping = aes(x = lon, y = lat, color = iso_country)) +
  geom_point()
```



A su vez podríamos realizar un boxplot para visualizar la dispersión que posee cada continente en torno a esta variable. Para ello podemos utilizar la función **geom\_boxplot()** para visualizar nuestras variables con esa geometría.

```
aeropuertos %>%
  ggplot(data = .,
    mapping = aes(x = continente, y = elevation_ft, color = continente)) +
  geom_boxplot()
```

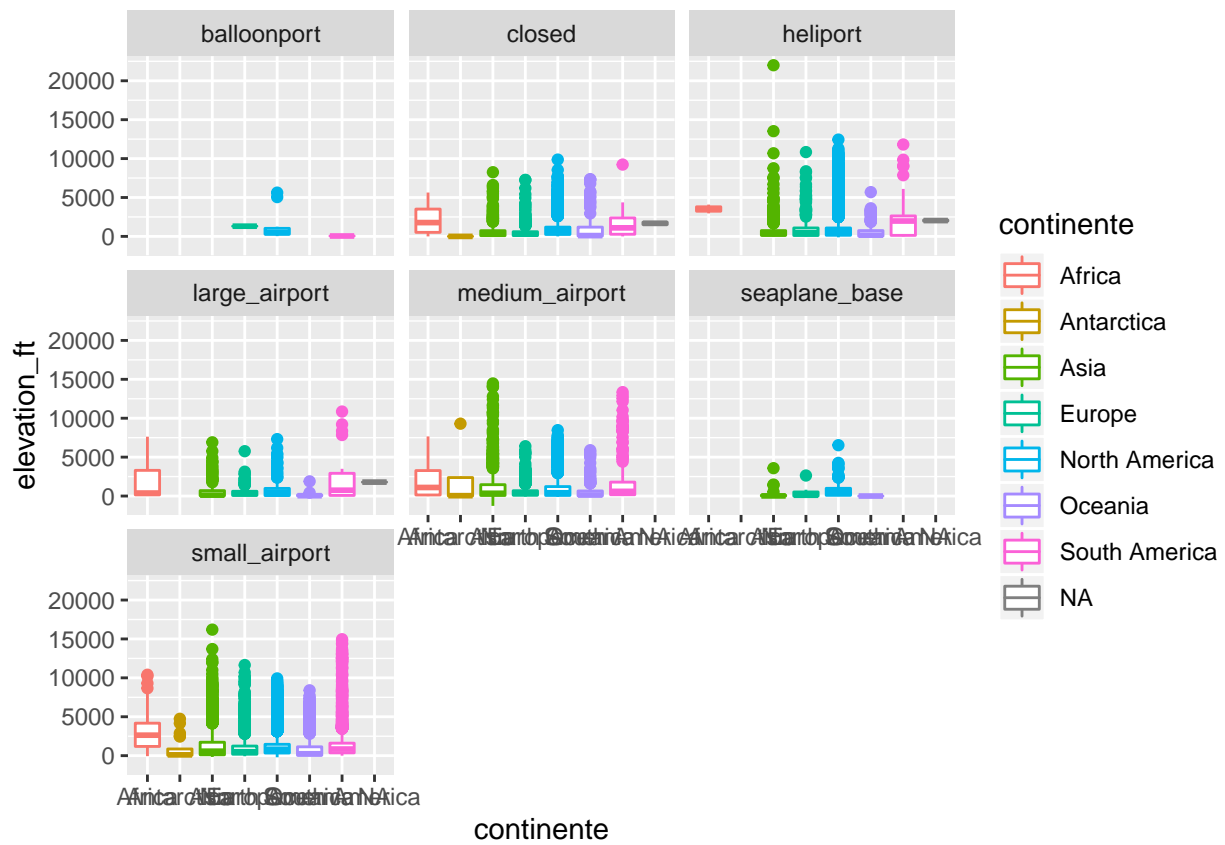
```
## Warning: Removed 7648 rows containing non-finite values (stat_boxplot).
```



Podemos a su vez subdividir nuestro analisis en base a continentes (o cualquier factor). Lo haremos con la función **facet\_wrap()**.

```
aeropuertos %>%
  ggplot(data = .,
    mapping = aes(x = continente, y = elevation_ft, color = continente)) +
  geom_boxplot() +
  facet_wrap(~type)
```

## Warning: Removed 7648 rows containing non-finite values (stat\_boxplot).



## Ejercicio