Manejo de datos en R (I)

Introducción a la Línea de Comandos para Análisis Bioinformáticos

10 de Agosto, 2021

Que vamos a hacer?

Manejo de datos y análisis reproducible

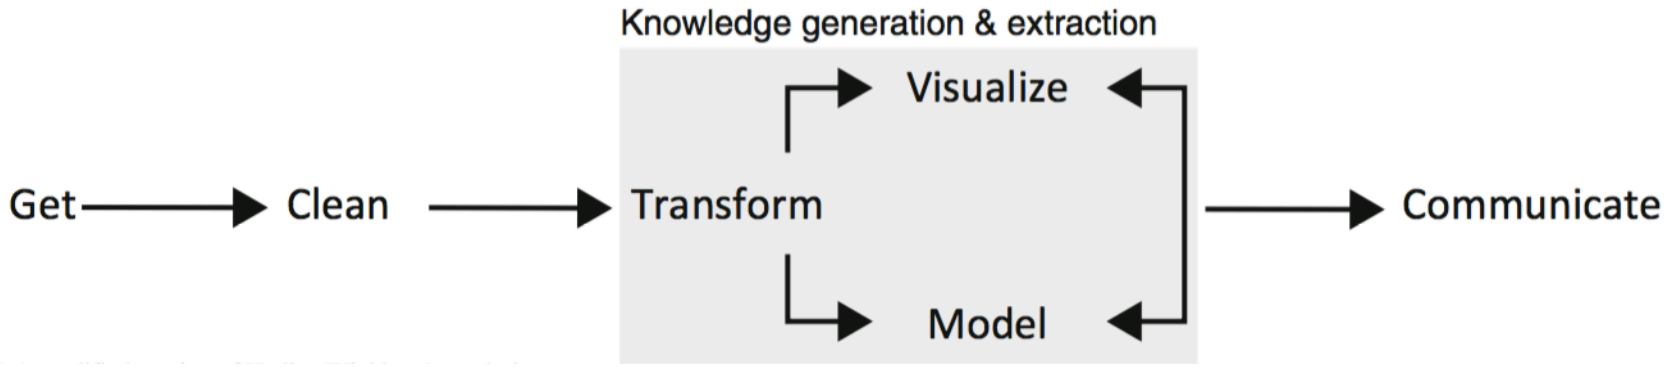

Data Wrangling with R (Boehmke, 2016)

Análisis reproducible en R

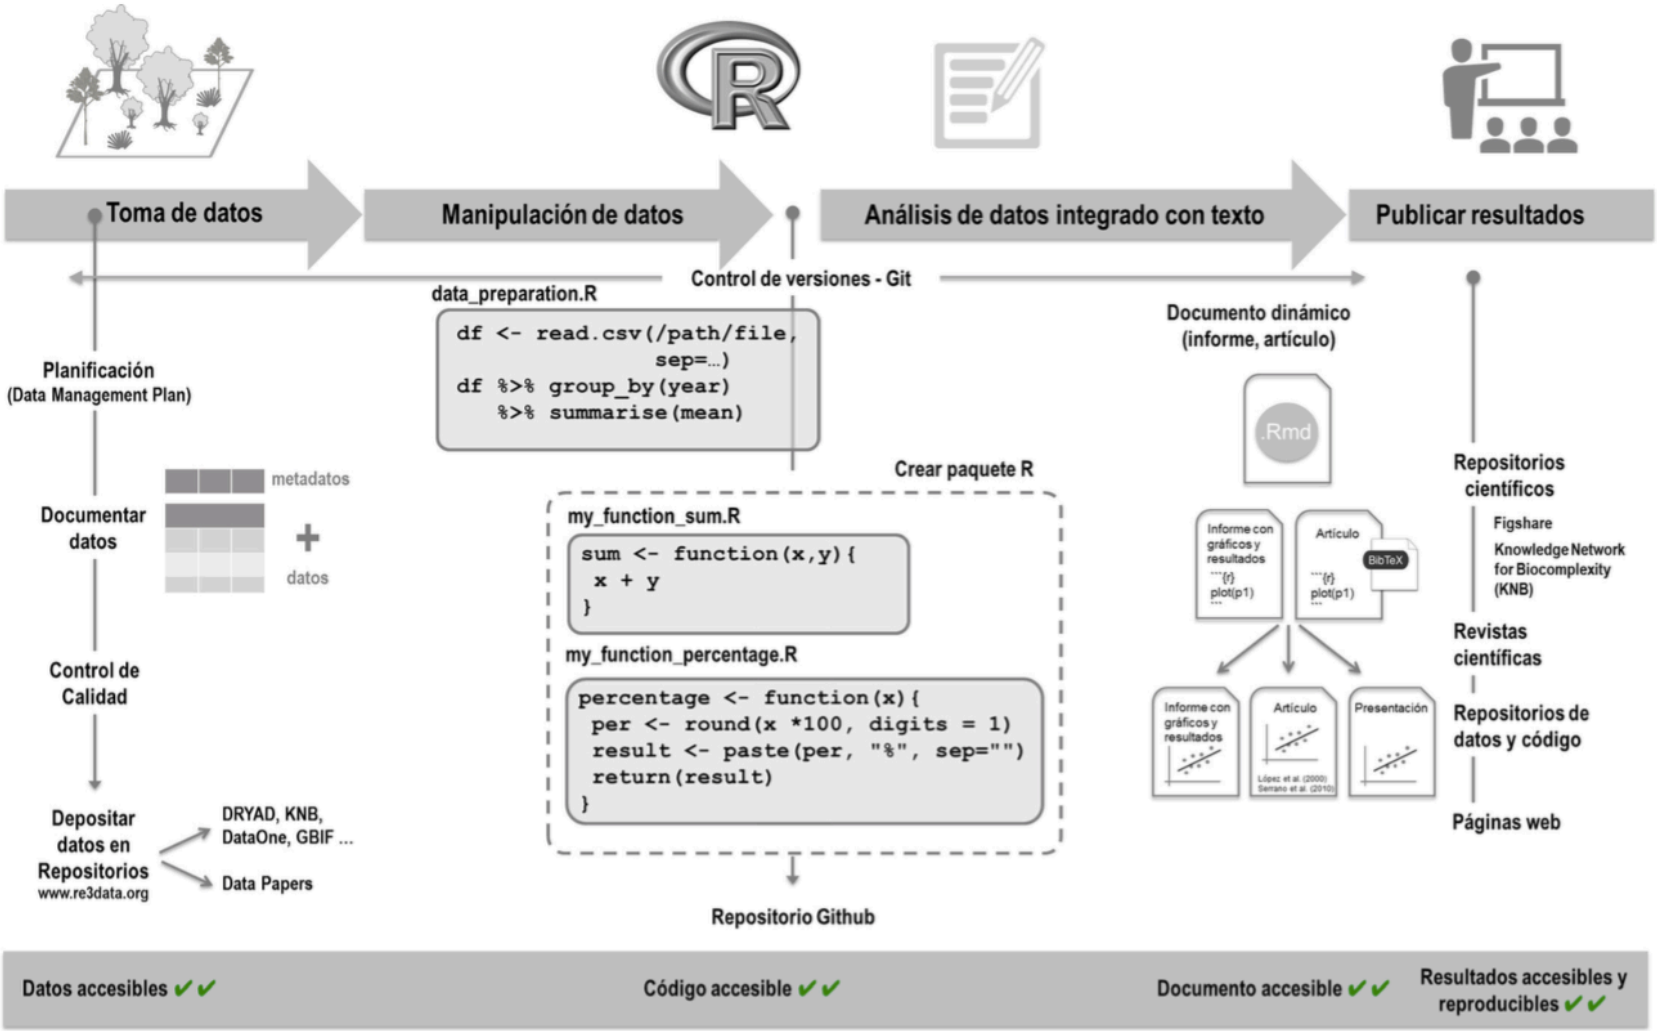

Ciencia reproducible: qué, por qué, cómo (Rodríguez-Sánchez et

Manejo de datos

- ***Data wrangling***: es el proceso mediante el cual modificamos datos iniciales con el fin de analizarlos.
- Incluye la edición, el filtrado, la obtención de nuevos valores y más.
- *"In our experience, the tasks of exploratory data mining and data cleaning constitute 80% of the effort that determines 80% of the value of the ultimate data mining results. (...)"*. **Dasu & Johnson.** *Exploratory Data Mining and Data Cleaning* (2003).

Análisis reproducible

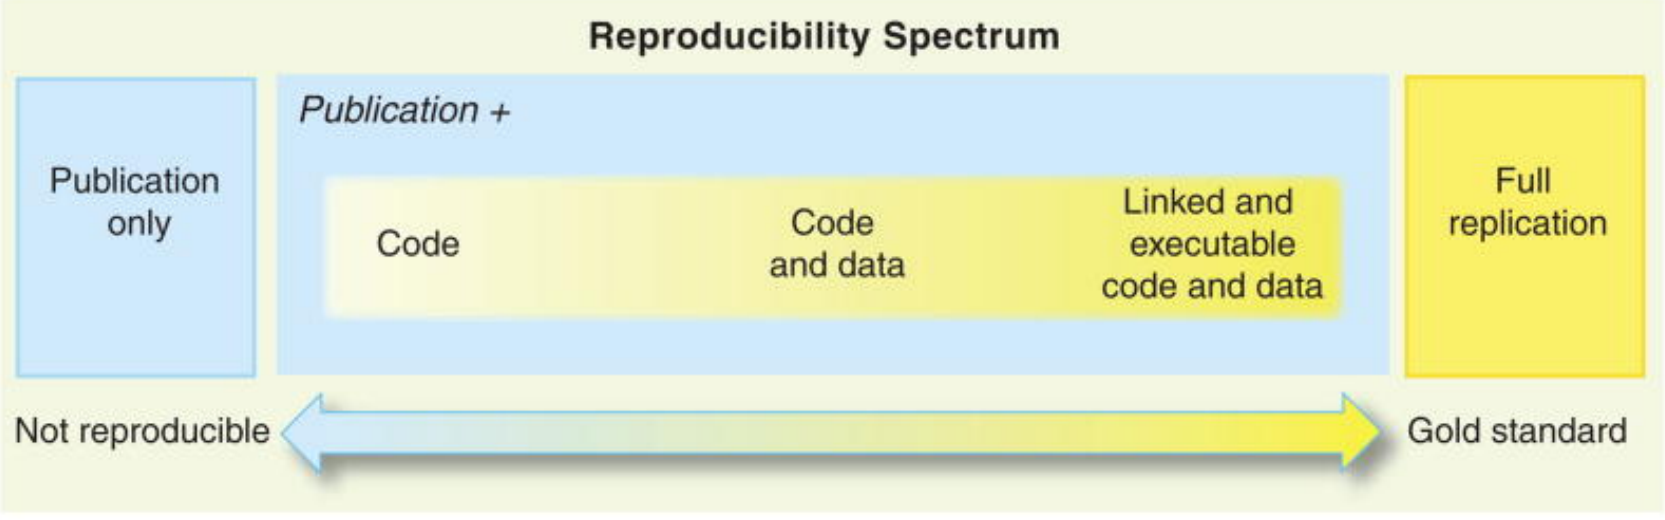

Reproducible Research in Computational Science (Peng, 2012)

- aca me falta una notita al pie con un warning message diciendo hasta donde vamos nosotros

Estructura de las clases

- Teórico/práctico.
- Práctico 11: repaso de loops y armado de funciones en R
  - accionar sobre los datos para transformarlos: funciones
  - realizar acciones repetitivas: loops
- Práctico 12: manejo de datos con paquetes de la librería **tidyverse**.
  - filtrado y edición de datos
  - visualización de los datos

Breve repaso de R

Breve repaso

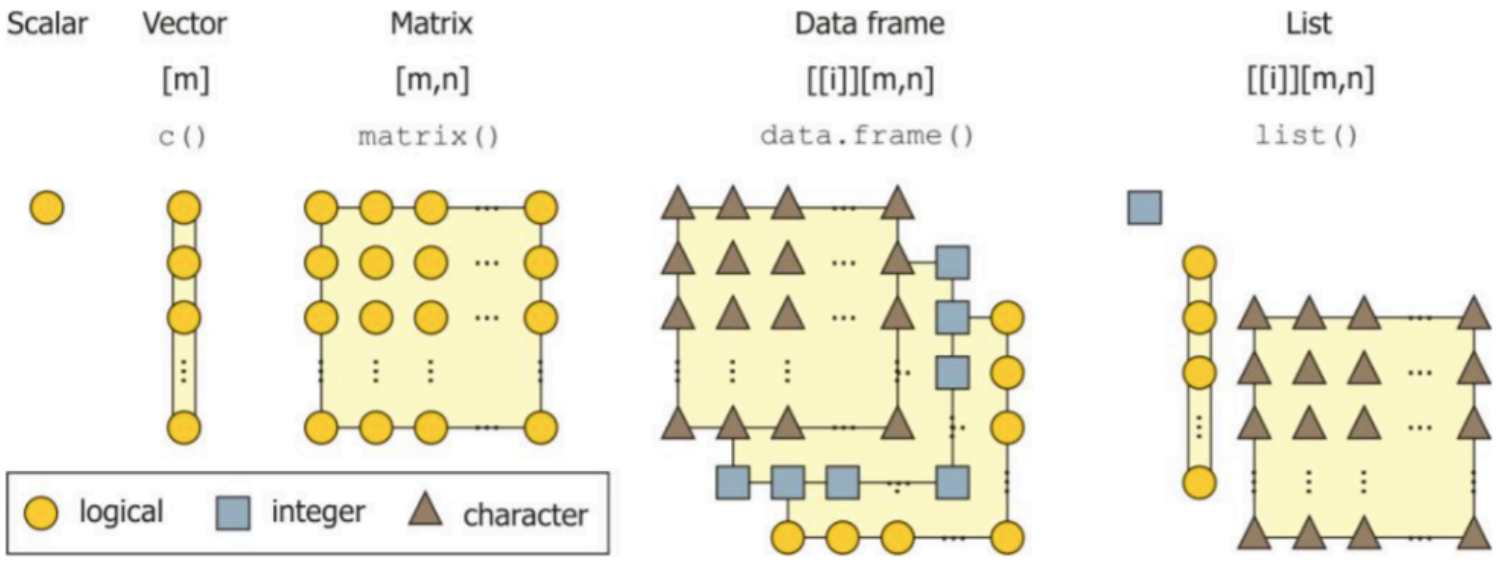

A practical guide to the R package Luminescence (Dietze et al., 2013)

Breve repaso

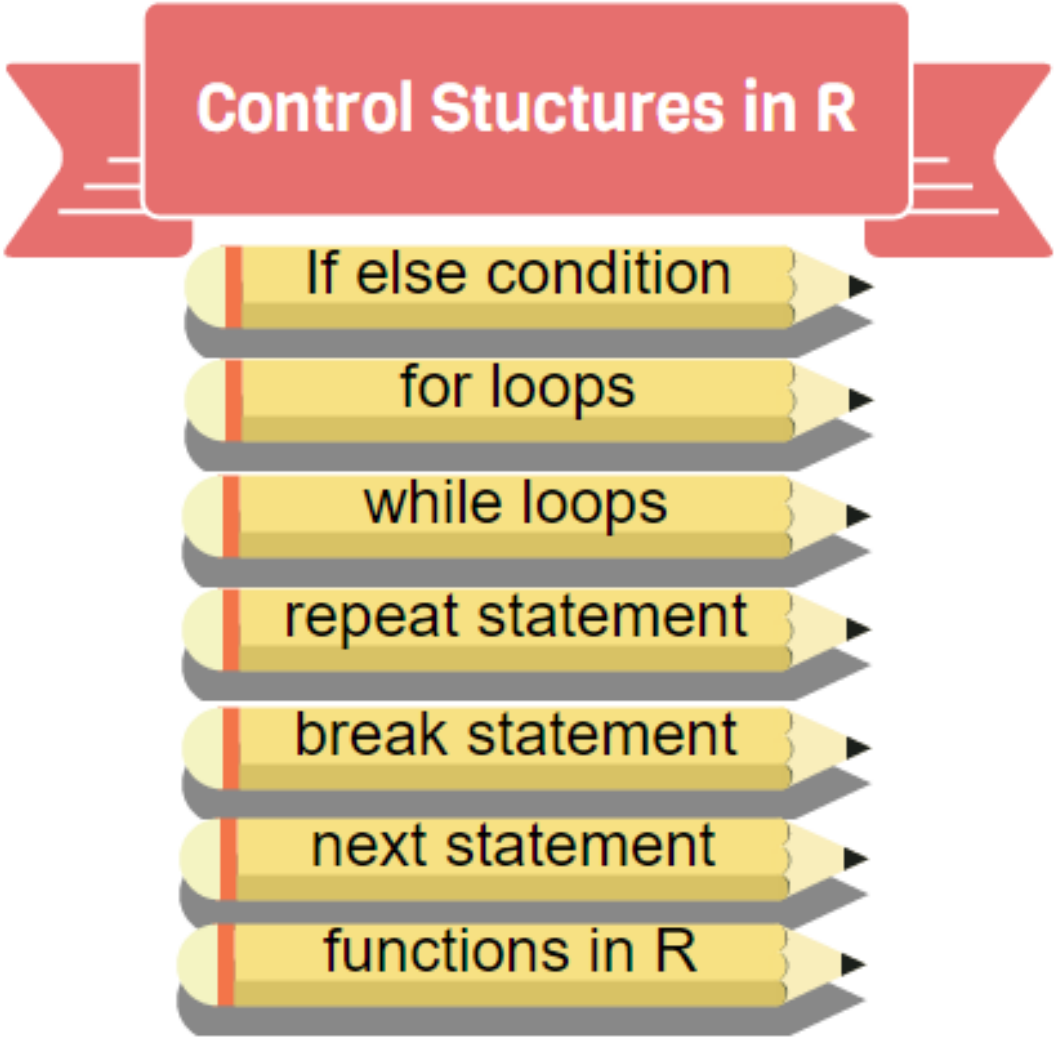

Breve repaso

Breve repaso

1. Basic Histogram

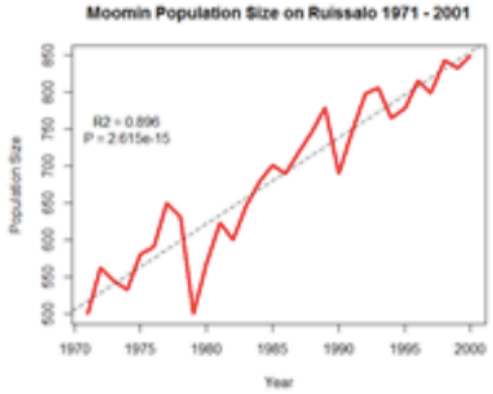

2. Line Graph with Regression

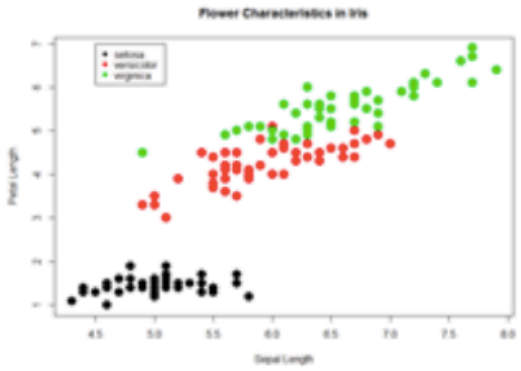

3. Scatterplot with Legend

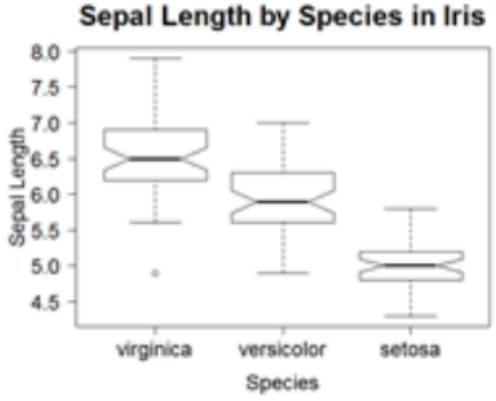

4. Boxplot with reordered/ formatted axes

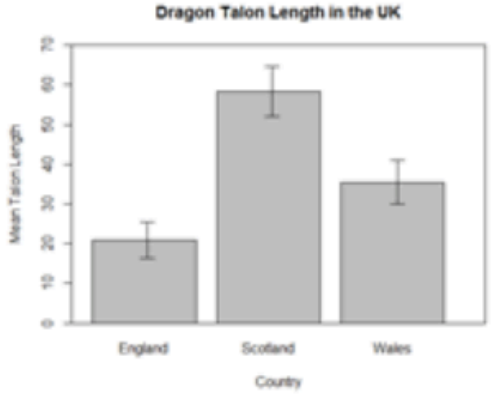

5. Boxplot with Error Bars

Funciones en R

Funciones: una parte central de R

- Qué es una función? -> Un conjunto de **operaciones** definidas que toman **argumentos** para dar un resultado.
- R Es un lenguaje de programación en base a funciones: casi todo lo que hacemos las utiliza.
  - Otros lenguajes operan de forma diferente.
- Ventajas
  - Le podemos dar nombre descriptivo
  - Nos ahorramos copiar y pegar codigo varias veces (y errar en el proceso)
  - Si hay que cambiar algo, es solo cambiar la funcion
- Las funciones en R salen de muchos lados:
  - R tiene funciones que vienen incorporadas por defecto
  - Utilizando librerías obtenemos nuevas funciones (como las de **seqinr**, por ejemplo)
  - Nosotros podemos hacer nuestras propias funciones

Componentes de una función

- **nombre** de la funcion. Es lo que nos permite referenciarla. Lo asignamos cuando la definimos
- **cuerpo**: el código que define a la función
- **formales**: la lista de argumentos que controlan cómo se llama a la función
- **ambiente**: el "mapa" de la locación de las variables de la función

Componentes de una función

```
library(seqinr)

body(seqinr::GC)
```

```
## {
##     if (length(seq) == 1 && is.na(seq))
##         return(NA)
##     if (nchar(seq[1]) > 1)
##         stop("sequence is not a vector of chars")
...
```

Componentes de una función

```
library(seqinr)

formals(seqinr::GC)
```

```
## $seq
##
##
## $forceToLower
## [1] TRUE
##
## $exact
## [1] FALSE
##
## $NA.GC
...
```

Componentes de una función

El *ambiente* de una funcion controla el modo en que R encuentra el valor asociado a un nombre.

```
library(seqinr)

environment(seqinr::GC)
```

```
## <environment: namespace:seqinr>
```

Funciones particulares

- Podemos, además, distinguir tipos especiales de funciones:
  - **Funciones primitivas**: llaman directamente a C
    - No tienen cuerpo ni formales.
  - **Funciones de alto rango**: operan sobre funciones
    - Tienen cuerpo y formales, pero constituyen un caso interesante en sí

Funciones primitivas

```
sum
```

```
## function (..., na.rm = FALSE)  .Primitive("sum")
```

```
body(sum)
```

```
## NULL
```

```
formals(sum)
```

```
## NULL
```

```
environment(sum)
```

```
## NULL
```

Funciones primitivas

```
`[`
```

```
## .Primitive("[")
```

```
`for`
```

```
## .Primitive("for")
```

```
`c`
```

```
## function (...)  .Primitive("c")
```

Definición de funciones

```
mi_funcion = function(argumento_1, argumento_2, ...){
#<-> el indentado no es obligatorio, pero ayuda a leer
  # en este bloque suceden operaciones con argumento_1
  ...
  # en este bloque suceden operaciones con argumento_2
  ...
  # se devuelve algo como resultado de aplicar
  # la funcion a los argumentos
  return(una_variable_nueva) # atencion: a veces una funci
} # una linea sola para este parentesis ayuda a leer
```

Definición de funciones

```
eleva_y_resta = function(x,y){
  resultado = x^2 - y^2
  return(resultado)
}
```

Definición de funciones

```
eleva_y_resta = function(x,y){
  resultado = x^2 - y^2
  return(resultado)
}

eleva_y_resta(2,3)
```

```
## [1] -5
```

Definición de funciones

```
eleva_y_resta = function(x,y){
  resultado = x^2 - y^2
  return(resultado)
}

eleva_y_resta(y = 2, x =3)
```

```
## [1] 5
```

Definición de funciones

```
eleva_y_resta = function(x,y){
  resultado = x^2 - y^2
  return(resultado)
}

eleva_y_resta(y = 2)
```

```
## Error in eleva_y_resta(y = 2): argument "x" is missing,
```

Definición de funciones

```
eleva_y_resta = function(x = 1, y =1){
  resultado = x^2 - y^2
  return(resultado)
}

eleva_y_resta(y = 2)
```

```
## [1] -3
```

Definición de funciones

```r
# ojo con el alcance de las variables!
x = 2
eleva_y_resta = function(x, y){
  resultado = x^2 - y^2
  return(resultado)
}

eleva_y_resta(y = 2) # nos juega una mala pasada el ambien
```

```
## [1] 0
```

Evitando problemas: *programación defensiva*

- la función **stop()** permite salir de la función si algo esperable no sucede

```
eleva_y_resta = function(x = 1, y =1){

  if(!is.numeric(x) || !is.numeric(y)){ # en condicionales como
    stop('Alguno de los argumentos dados no es un numero.')
  }

  resultado = x^2 - y^2
  return(resultado)
}

eleva_y_resta(x = 2, y = "2")
```

```
## Error in eleva_y_resta(x = 2, y = "2"): Alguno de los argumen
```

Salida de funciones

```r
# ojo con el alcance de las variables!
x = 2
eleva_resta_y_suma = function(x, y){
  resta = x^2 - y^2
  suma = x^2 + y^2
  return(c(resta, suma))
}

eleva_resta_y_suma(x = 2, y = 2)
```

```
## [1] 0 8
```

Salida de funciones

```
# ojo con el alcance de las variables!
x = 2
eleva_resta_y_suma = function(x, y){
  resta = x^2 - y^2
  suma = x^2 + y^2
  return(c(list(resta, suma)))
}

eleva_resta_y_suma(x = 2, y = 2)
```

```
## [[1]]
## [1] 0
##
## [[2]]
## [1] 8
```

Funciones de alto rango (*high-order functions*)

- Son funciones que toman a otras funciones como argumentos y devuelven una función o valor.
- Funciones como apply(), sapply(), lapply(), mapply()...

sapply

```r
# definimos un vector
numeros = c(1,2,3,4)

# aplicamos una funcion anonima sobre este vector
numeros_cuadrado = sapply(X = numeros, FUN = function(x){x^2})

numeros_cuadrado
```

```
## [1]  1  4  9 16
```

lapply

```r
# definimos un vector
numeros = c(1,2,3,4)

# aplicamos una funcion anonima sobre este vector
numeros_cuadrado = lapply(X = numeros, FUN = function(x){x^2})

numeros_cuadrado
```

```
## [[1]]
## [1] 1
##
## [[2]]
## [1] 4
...
```

mapply

```
# creando una matriz de 4x4 con mapply
matriz = mapply(rep, 1:4, 4)

matriz
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    1    2    3    4
## [2,]    1    2    3    4
## [3,]    1    2    3    4
## [4,]    1    2    3    4
```

Loops en R

For loop (abstracto)

```
# for loop

un_vector = ...
for (i in ____) {
   ...
   ... un_vector[i] ....
   ...
}
```

For loop (ejemplo)

```
numeros = c(3,40,15,6)
numeros_cuadrado = c()

for (i in 1:length(numeros)) {
  numeros_cuadrado[i] = numeros[i]^2
}
```

For loop (usando seq_along())

```
numeros = c(3,40,15,6)
numeros_cuadrado = c()

for (i in seq_along(numeros)) {
  numeros_cuadrado[i] = numeros[i]^2
}
```

Operador next

```
numeros = c(3,40,15,6)
numeros_cuadrado = c()

for (i in seq_along(numeros)) {

  if(!numeros[i] %% 3 == 0){
    next
  }
  else {
  numeros_cuadrado[i] = numeros[i]^2
  }
}
numeros_cuadrado
```

```
## [1]   9  NA 225  36
```

Operador break

```
numeros = c(3,40,15,6)
numeros_cuadrado = c()

for (i in seq_along(numeros)) {

  if(!numeros[i] %% 3 == 0){
    break
  }

  numeros_cuadrado[i] = numeros[i]^2
}
numeros_cuadrado
```

```
## [1] 9
```

While loop

- Sigue la misma lógica que en Bash
- Se utiliza la función while() en vez de for()
- Se puede realizar combinando un for loop con un operador break

Comentarios, dudas existenciales?

A programar se ha dicho :)

- 10 minutos de pausa y volvemos.
- El practico de hoy esta en este link (clickear).
- passwd: **HfqsRNA2_**